Машинное обучение для выбора численного метода

решения линейных дифференциальных уравнений второго порядка

Третья часть научно-исследовательского отчёта по проекту №2488

1 Исследовательская задача

Численное решение дифференциального уравнения определяется не только выбранной схемой, но и свойствами коэффициентов, правой части, решения и значениями параметров дискретизации. Одинаковое число итераций может оказаться достаточным для одного уравнения и недостаточным для другого. Стохастический метод дополнительно зависит от случайного набора траекторий. Поэтому фиксированный выбор метода и вычислительного бюджета не обязан быть эффективным для всего рассматриваемого класса задач.

В предыдущих частях исследованы метод Ремизова и метод Монте-Карло для одной резольвентной постановки. Настоящая работа посвящена возможности предварительно выбирать способ вычисления по характеристикам заданного уравнения. Требуется учитывать одновременно точность и время: быстрый, но неточный ответ не решает поставленную задачу, а заведомо избыточные вычисления повышают стоимость точной доставки. При этом существование единственного лучшего метода для каждого уравнения не предполагается: возможны несколько допустимых вариантов, отсутствие точного ответа среди испытанных приближений и неопределённость стохастического результата.

Цель исследования — построить и независимо проверить обучаемое правило выбора между двумя приближениями Ремизова и одним приближением Монте-Карло. Для этого сформированы признаки коэффициентов, обучены прогнозы достижения допуска и времени, исследована калибровка вероятностей, выбрана политика по семейной перекрёстной проверке и проведено сопоставление с постоянными стратегиями. Научный результат оценивается по фактическим точным доставкам и затратам, а не по обязательному превосходству обучаемого правила.

2 Математическая постановка и критерий точности

Рассматривается исходное уравнение

$$a(x)y''(x) + b(x)y'(x) + c(x)y(x) = g(x), \qquad x \in \mathbb{R}. \tag{1}$$

Здесь x — независимая переменная, y — искомая функция; a, b, c — коэффициенты, g — заданная правая часть. Для исследуемых гладких ограниченных функций имеются глобальные оценки

$$0 < \underline{a} \le a(x) \le \overline{a}, \quad |b(x)| \le B, \quad |c_R(x)| \le C, \quad \lambda > C, \tag{2}$$

где $\underline{a}, \overline{a}, B, C$ — известные числовые границы, λ — параметр резольвенты. Границы не обязаны быть точными экстремумами. Связь с исходным уравнением задаётся равенствами

$$c_R = c + \lambda, \quad g_R = -g, \quad L = a(x)\partial_x^2 + b(x)\partial_x + c_R(x), \quad (\lambda - L)y = g_R. \tag{3}$$

Последнее равенство после умножения на -1 возвращает (1). Ищется решение, ограниченное на всей прямой. Это дополнительное условие выбора решения, отличное от начальных условий задачи Коши. Если в данных заданы $y(-1)$ и $y'(-1)$, они получены из известного точного решения и совместимы с ним; произвольные другие начальные условия определяли бы другую задачу.

Для оператора L используется резольвентное представление

$$y(x) = \int_0^\infty e^{-\lambda t}(e^{tL}g_R)(x)\,dt, \qquad y_{n,T}(x) = \int_0^T e^{-\lambda t}(S(t/n)^n g_R)(x)\,dt, \tag{4}$$

где e^{tL} — полугруппа, S — аппроксимирующий оператор Чернова, t — переменная интегрирования, T — предел усечения, n — число последовательных применений S. В оператор входит именно c_R, а не c. При Монте-Карло то же представление оценивается по случайным траекториям; диффузия имеет вид $dX_t = b(X_t)dt + \sqrt{2a(X_t)}\,dW_t$, где W_t — стандартное броуновское движение. Подробные схемы исследованы ранее; здесь они не меняются.

Сравнение выполняется на отрезке $[-1, 1]$ в фиксированных узлах $x_i = -1 + i/16$, $i = 0, \ldots, 32$. Для сохранённого приближения $\widetilde{y}_j$ определяются

$$E_j = \max_{0\le i\le 32} |\widetilde{y}_j(x_i) - y_{\text{exact}}(x_i)|, \qquad Z_j = \mathbf{1}\{E_j \le \varepsilon\}, \qquad \varepsilon = 0{,}01. \tag{5}$$

Индекс j обозначает метод вместе с его фиксированными параметрами, Z_j — индикатор точной доставки. В материалах нет отдельного физического обоснования величины $0{,}01$; это установленный критерий эксперимента. Он относится к максимуму в 33 узлах, не к непрерывной норме на всём отрезке и тем более не на $\mathbb{R}$. Успешное завершение вычисления также не означает $Z_j = 1$.

Изучаются Ремизов с $n = 128$, Ремизов с $n = 256$ и Монте-Карло с $M = 4096$ траекториями на каждую пространственную точку. При Ремизове использованы 513 узлов квадратуры, $\Delta x = 0{,}0125$, кубические сплайны и нулевое продолжение вне рабочего отрезка $[-13, 13]$. Этот отрезок не заменяет область исходной задачи. Для Монте-Карло требуемый шаг равен $1/128$, фактический — $T/N \le 1/128$, где N — число шагов траектории. Удвоение n исследовалось как более затратное уточнение, но не как теорема о двукратном уменьшении ошибки.

3 Формирование уравнений и экспериментальных данных

Уравнения строились с заранее известным решением. Сначала задавались гладкие ограниченные композиции A, B_0, C_0, H из констант, синусов, косинусов, гиперболических тангенсов, гауссовых и рациональных функций, их линейных комбинаций и произведений. Затем применялись преобразования

$$a = A_m + A_h \tanh A, \quad b = B\tanh B_0, \quad c_R = C\tanh C_0, \quad \lambda = C + \delta, \quad \delta > 0. \tag{6}$$

При $A_m > A_h > 0$ они обеспечивают (2) на всей прямой. Различались четыре уровня сложности композиционных деревьев и пять режимов коэффициентов: постоянный, медленно меняющийся, умеренный, осциллирующий и контрастный. Это способы конструирования разнообразных задач, а не доказанная шкала трудности для каждого метода.

Точное решение имело компактный носитель:

$$y_{\text{exact}}(x) = sW_{\mu,\rho}(x)H(x), \quad W_{\mu,\rho}(x) = \begin{cases} \exp\!\left(1 - \dfrac{1}{1-((x-\mu)/\rho)^2}\right), & |x-\mu| < \rho, \\ 0, & |x-\mu| \ge \rho. \end{cases} \tag{7}$$

Здесь μ — центр носителя, $\rho > 0$ — его радиус, $s > 0$ — масштаб. Правая часть получалась аналитической подстановкой $g = ay''_{\text{exact}} + by'_{\text{exact}} + cy_{\text{exact}}$. Так обеспечивалось известное ограниченное решение и возможность измерять полную сеточную ошибку. Это изготовление проверочных задач, а не утверждение о возможности аналитически решать произвольное входное ОДУ.

Покажем реальное уравнение с постоянными коэффициентами (пример 1 приложения А). Обозначим через a_1, b_1, c_1 числа

$$\begin{aligned} a_1 &= 1.983925129927827 + 0.4948927992340211\tanh(-0.9445099704819986),\\ b_1 &= 1.2736839759694616\tanh(-1.4320384163375453),\\ c_1 &= 1.2336798048825266\tanh(-1.0418788348584225) - 1.6551040450654098. \end{aligned} \tag{8}$$

Исходная задача имеет вид $a_1 y'' + b_1 y' + c_1 y = g_1(x)$. Её точное решение задаётся (7), где

$$\begin{aligned} s = 0.4496376326792234,\quad \mu = 0.12552944688615264,\quad \rho = 2.7787272448026363,\\ H(x) = 1.4204653788060875e^{-1.6583964568669665(x+0.7759412582493684)^2}\\ + 1.4499935751532103\cdot 0.774948700390804. \end{aligned} \tag{9}$$

Полная замкнутая правая часть g_1, её вспомогательные функции и совместимые начальные данные даны в п. А.1; это то же уравнение, а не его упрощённый аналог. При $n = 128$ ошибка равна 0,00291937, при $n = 256$ — 0,00146141: оба приближения допустимы. Монте-Карло в сохранённой реализации дал 0,01026241, то есть нарушил порог, несмотря на близость к нему. Графики Б.1–Б.4 позволяют отделить постоянство коэффициентов от непостоянной правой части и асимметричного решения.

Семейство определялось топологией четырёх композиционных деревьев; изменение числовых параметров внутри одной топологии не создавало независимое семейство. Поэтому случайное разделение отдельных уравнений могло бы перенести родственные конструкции и в обучение, и в проверку. До обучения разделялись семейства; повторные записи одного расчёта удалялись, а независимые реализации Монте-Карло сохранялись как повторные наблюдения одного уравнения.

Обучающие данные точности для $n = 128$ содержали 103 случая из 90 семейств, для $n = 256$ — 40 случаев из 40 семейств. Для Монте-Карло имелось 40 уравнений и 180 различных случайных реализаций, из которых 12 достигли допуска. Нельзя считать эти 180 реализаций 180 независимыми уравнениями. Для времени использованы только сопоставимые измерения: 9 для $n = 128$, 36 для $n = 256$ и 40 для Монте-Карло после агрегации повторов по уравнению и профилю. Отсутствующее время не заменялось вымышленным наблюдением.

4 Вероятностная модель и правило выбора

Входом модели служили только заданные коэффициенты a, b, c, g на 256 узлах и их допустимые аналитические характеристики, но не точное решение, его производные, численные ответы или ошибка. Получены 253 признака: 128 выборочных значений функций, 56 статистик уровня, вариации, конечных разностей и спектрального состава, 6 межканальных корреляций, 48 характеристик структуры коэффициентов и 15 глобальных оценок и производных от них масштабов. Каналы c_R и g_R получаются из исходных коэффициентов по (3), поэтому не добавляют скрытой информации о целевом ответе. Структурные признаки описывают только коэффициенты, не дерево известного решения.

Вариация, производные и спектральный состав потенциально характеризуют изменение функций; глобальные границы задают масштаб дрейфа, диффузии и затухания. Однако их информативность для конкретной ошибки исследуется статистически. Само наличие частых колебаний не доказывает большого значения E_j.

Обучение и калибровка проверялись трёхблочной перекрёстной проверкой по семействам. Для каждого внешнего блока все его семейства исключались из обучения, внутренней калибровки и выбора политики. Калибратор обучался на отдельных внутренних трёхблочных прогнозах. Среди 20 сохранённых правил сравнивались пороговые варианты, близость вероятностей, стоимость успеха и постоянный выбор. Внутренний эмпирический отбор требовал отсутствия индивидуальных потерь точных доставок относительно постоянного $n = 256$, затем максимизировал число точных ответов и минимизировал прогнозируемую стоимость. Это обучающий критерий, не доказательство безопасности на популяции. Окончательная политика выбрана по всем разрешённым обучающим данным; её оценка после такого отбора не выдавалась за независимую. Ранее просмотренные проверочные данные для настройки не использовались.

Для вектора признаков z обучались отдельные прогнозы вероятности успеха

$$p_j(z) = \Pr\{E_j \le 0{,}01 \mid z, j\}. \tag{10}$$

У Монте-Карло вероятность относится также к новой случайной реализации при фиксированном профиле. У детерминированного метода она выражает неопределённость прогноза по классу уравнений, а не случайность повторного исполнения одной задачи. Для обучения использованы ансамбли градиентного бустинга над деревьями (CatBoost): 120 деревьев глубины 2, шаг обучения $0{,}05$ и регуляризация листьев 10. Эти настройки фиксировались, их преимущество перед всеми альтернативными алгоритмами не установлено.

Если из m_{ij} реальных повторов уравнения i точны k_{ij}, целевое значение равно $q_{ij} = k_{ij}/m_{ij}$. У Ремизова повторные детерминированные ответы дают одну метку; у Монте-Карло число различных реализаций входит в биномиальную функцию потерь:

$$\mathcal{L}_j = -\sum_i w_i m_{ij} \{ q_{ij} \log p_j(z_i) + (1 - q_{ij}) \log[1 - p_j(z_i)] \}. \tag{11}$$

Вес w_i обратен числу уравнений соответствующего семейства среди обучающих строк. Это ограничивает перевес многократно представленных родственных конструкций; множитель m_{ij} учитывает реальное число стохастических наблюдений. Признаки стандартизировались по статистикам только обучающей части каждого разбиения.

Вероятности калибровались регуляризованным сигмоидальным преобразованием

$$\widehat{p}_j = \sigma\big(\alpha_j \operatorname{logit}(p_j^{\text{raw}}) + \beta_j\big), \quad \sigma(v) = (1 + e^{-v})^{-1}, \quad \operatorname{logit}(p) = \log \frac{p}{1-p}. \tag{12}$$

Перед logit значения ограничивались интервалом $[10^{-6}, 1 - 10^{-6}]$. Параметры α_j, β_j подбирались по прогнозам на исключённых целых семействах с добавкой $(\alpha_j - 1)^2 + \beta_j^2$ к потере при $0 \le \alpha_j \le 10$, $|\beta_j| \le 10$. Калибровка улучшает согласование прогнозов с наблюдениями на доступных данных, но не создаёт сертификата надёжности каждого уравнения.

Время предсказывалось отдельно: общая регрессия для Ремизова использовала цель $\log(t/n)$, а для Монте-Карло — $\log t$. Поэтому

$$\widehat{t}_{R,n}(z) = n \exp F_R(z), \qquad \widehat{t}_M(z) = \exp F_M(z). \tag{13}$$

Линейное масштабирование по n является предположением модели времени, а не теоремой о точности или стоимости любого алгоритма. Модели не обучались на недостающих вымышленных временах.

Пусть $J = \{R_{128}, R_{256}, M\}$. Замороженная политика использует

$$p_* = \max_{j \in J} \widehat{p}_j, \qquad \mathcal{A} = \{ j \in J : \widehat{p}_j \ge p_* - 0{,}02 \}, \quad \mathcal{A}_R = \mathcal{A} \cap \{R_{128}, R_{256}\}. \tag{14}$$

Если $\mathcal{A}_R \neq \varnothing$, выбирается $r_* \in \mathcal{A}_R$ с наименьшим $\widehat{t}$; при равенстве предпочтён $n = 128$. Итоговое правило в точности имеет вид

$$\widehat{j} = \begin{cases} M, & \mathcal{A}_R = \varnothing, \\ M, & M \in \mathcal{A},\ \widehat{t}_M \le 0{,}9 \widehat{t}_{r_*}, \\ r_*, & \text{иначе.} \end{cases} \tag{15}$$

Так сохраняются близкие по вероятности варианты и требуется не менее 10% прогнозной экономии для выбора Монте-Карло вместо подходящего приближения Ремизова. Абсолютного порога $0{,}95$ в этом правиле нет: непустое $\mathcal{A}$ возможно и при низких вероятностях, поэтому фактический ответ может оказаться неточным.

5 Методика независимой проверки

После заморозки модели и правила (15) отобраны 60 новых семейств, топологически не пересекающихся с прежними задачами: по три на каждую из 20 комбинаций сложности и режима. Отбор был определён до численных исходов, без поиска благоприятных ошибок. На каждом уравнении измерены оба варианта Ремизова; Монте-Карло выполнен на 20 заранее выбранных задачах, по одной на ячейку. Так получены 140 вызовов. Уменьшение объёма стохастической части сохраняет полное сравнение фактических решений модели с двумя базовыми стратегиями, поскольку все замороженные решения выбрали Ремизова: 21 раз $n = 128$, 39 раз $n = 256$.

Для основной оценки повторно использовалось одно и то же измерение выбранного приближения, а не дополнительное решение. Измерялось полное время тёплого вызова метода в одном окружении; общей загрузки, подготовки среды и компиляции в нём нет. Для модели добавлено ранее измеренное время получения признаков и прогноза. Поэтому оценка не равна всей задержке возможного практического развёртывания. Порядок измерений сбалансирован; один замер на профиль не оценивает его повторный временной разброс.

6 Результаты независимого эксперимента

Таблица 1. Точность и вычислительная стоимость на 60 новых семействах

Метод выбора	Точных ответов	Время, с	Отказов
Машинное обучение	57 из 60	1164,27	0
Ремизов, $n = 256$	57 из 60	1411,01	0
Ремизов, $n = 128$	53 из 60	706,41	0

Результат 57 из 60 означает, что в трёх сохранённых ответах максимум (5) превысил допуск. Отказов и вычислительных сбоев не было; неточные ответы также оплачены. Суммарное время модели включает $0{,}103670$ с ранее измеренных затрат на признаки и прогноз. Относительная экономия к постоянному $n = 256$ равна

$$\frac{1411{,}006868253 - 1164{,}270215714}{1411{,}006868253} \cdot 100\% = 17{,}4866\% \approx 17{,}49\%. \tag{16}$$

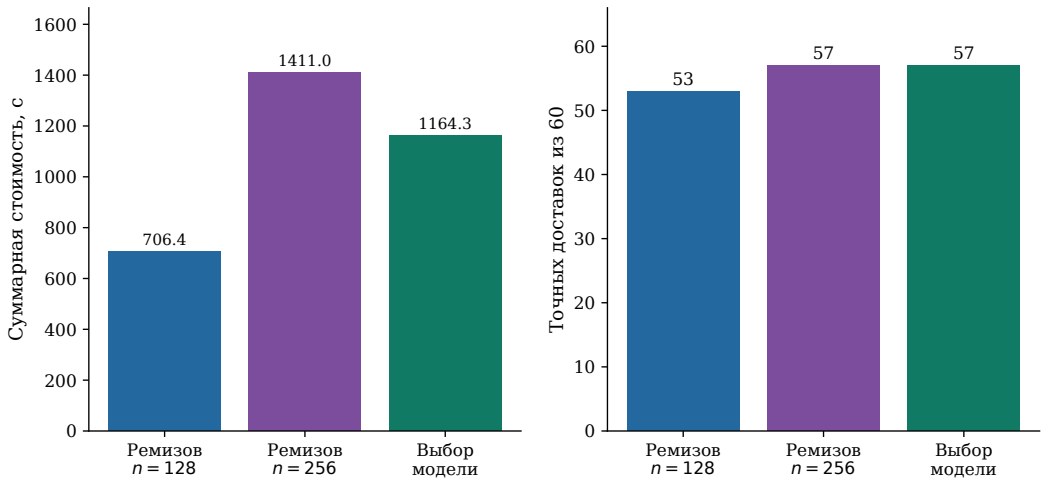


Рис. 1. Число точных доставок и стоимость на одной финальной выборке. Самый дешёвый постоянный вариант менее точен; обучаемый выбор не доминирует обе стратегии одновременно.

Относительно постоянного $n = 128$ модель получила ещё четыре точных ответа, сохранив все его 53 точные доставки, но затратила на 64,82% больше времени. Стоимость на точную доставку составила соответственно 20,426 с для модели, 24,755 с для $n = 256$ и 13,328 с для $n = 128$. Разные знаменатели здесь существенны: дешёвые неточные ответы нельзя исключать из оплаченных затрат.

Распределения ошибок на рис. 2 показывают, что одинаковое число точных ответов не означает одинаковые ошибки. Выбор более дешёвого допустимого приближения может увеличивать ошибку, не пересекая порог. Монте-Карло анализируется отдельно: все 20 вычислений завершены, но ни одно не достигло допуска. Для остальных 40 его точность неизвестна. Нельзя ни смешивать знаменатели 20 и 60, ни считать неизмеренные варианты неудачными.

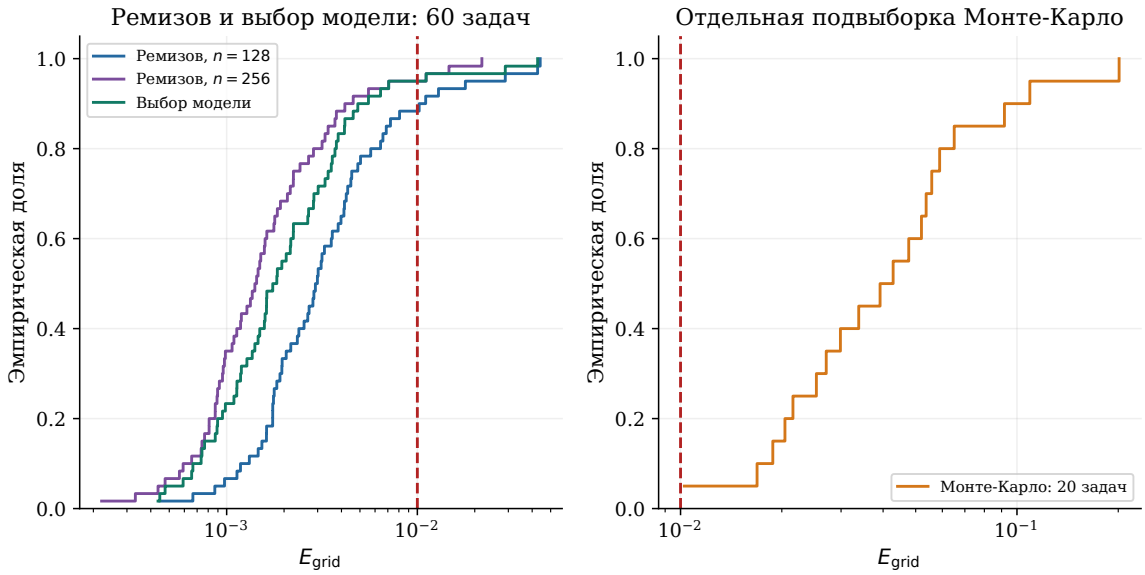


Рис. 2. Эмпирические распределения сеточной ошибки. Для Ремизова и модели использованы 60 задач, для Монте-Карло — 20. Вертикаль соответствует допуску 0,01.

Неопределённость оценивалась парным повторным отбором семейств; подробности приведены в приложении B. Вырожденный интервал разности точности с $n = 256$ не доказывает равенства рисков. Наблюдаемые $57/60 = 95\%$ не гарантируют надёжность следующего ответа 95%.

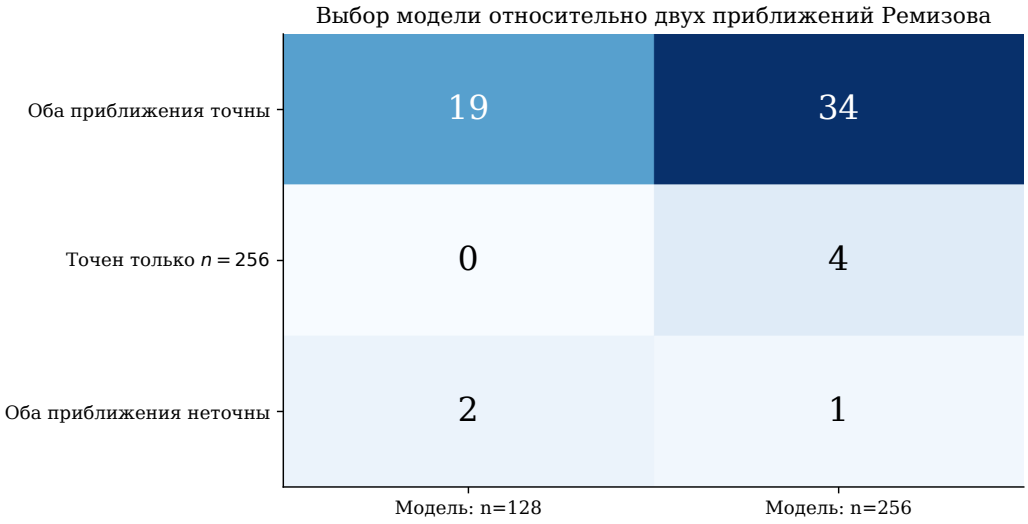


Рис. 3. Выбор модели относительно двух измеренных приближений Ремизова: 19 экономных точных выборов, 4 необходимых уточнения, 34 избыточно дорогих точных ответа и 3 неточных.

7 Характерные уравнения и неоптимальные решения

Пример 1 с уравнением (8) и точным решением (9) показывает достаточность меньшего вычислительного бюджета. Коэффициенты постоянны, но правая часть и решение меняются. Сравнение Б.1–Б.4 показывает, что визуальное совпадение кривых недостаточно для принятия решения: отдельная МС-ошибка чуть выше $0{,}01$ остаётся нарушением допуска.

В примере 3, полностью заданном формулами п. А.3, коэффициенты меняются умеренно, а решение имеет вид (7) с $s = 6.034151780918269$, $\mu = -0.03666028004499061$, $\rho = 1.7373814842542066$. Его функция формы равна

$$\begin{aligned} H_3(x) = {} & e^{-\cos^2(0.162537284342751x + 0.4547833238272104)} \\ & \times \big[-0.8980719428395056 \tanh(-0.3613725371874747x - 1.1967457073726797) \\ & \quad - 0.6907321591909864 e^{-0.46929024038993034(x - 1.3123761993740666)^2}\big]. \end{aligned} \tag{17}$$

Исходное уравнение здесь $a_3 y'' + b_3 y' + c_3 y = g_3$ с явными числовыми коэффициентами п. А.3; оно не заменяется уравнением с усреднёнными коэффициентами. Уточнение действительно пересекает допуск, хотя различие кривых решений на общем масштабе мало (рисунки Б.9–Б.12).

Для контраста пример 5 (п. А.5) имеет несколько экстремумов и меняющее знак решение $y = sW_{\mu,\rho}H_5$, где $s = 0.4266912316222408$, $\mu = 0.20899798693774746$, $\rho = 1.9721061459030749$; полное числовое определение H_5, коэффициентов и правой части приведено там же. Оба приближения нарушают порог. Уточнённая ошибка на части узлов допустима, но её максимум всё ещё велик (Б.17–Б.20).

Таблица 2. Три характерных случая; полные постановки — в приложении А

Пример	Наблюдение	E_{128}	E_{256}
1	Оба приближения точны	0,00291937	0,00146141
3	Уточнение достигает допуска	0,01022150	0,00376125
5	Оба приближения неточны	0,04272617	0,02179748

В целом на 57 задачах с хотя бы одним точным приближением Ремизова модель выбрала самое быстрое точное приближение лишь в 23 случаях. В 34 случаях она предпочла более дорогой $n = 256$ при точном $n = 128$. Матрица на рис. 3 также выделяет три задачи, где оба варианта неточны. Следовательно, экономия к одной базовой стратегии не равнозначна оптимальному выбору на каждом уравнении. Форма коэффициентов на рисунках описывает наблюдаемый пример, но не устанавливает причину ошибки или порядок сходимости.

8 Обсуждение и научные выводы

Независимая проверка подтвердила ограниченный, но содержательный эффект: на 60 новых семействах обучаемое правило сохранило все 57 точных доставок постоянного $n = 256$ и уменьшило измеренную стоимость на 17,49%. Результат не является доминированием обеих базовых стратегий: $n = 128$ дешевле, но даёт 53 точных ответа. На рис. 4 приведены парные измерения и накопленная стоимость без утверждения об устойчивом времени каждого нового запуска.

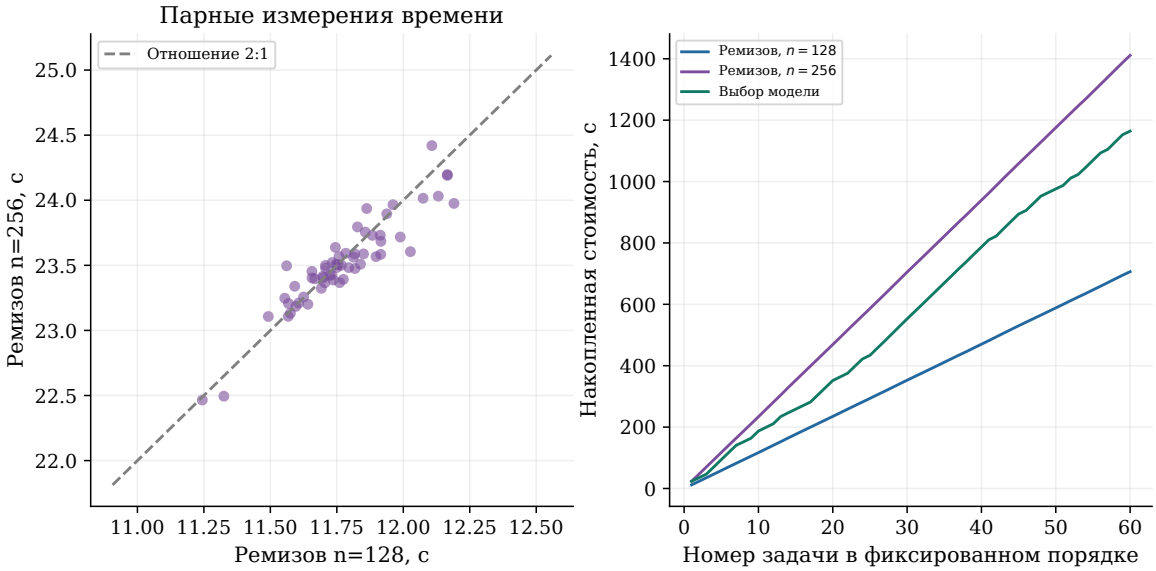


Рис. 4. Сопоставимые времена и накопленная стоимость по фиксированному порядку 60 задач. Повторное использование одного измерения сохраняет парность сравнения стратегий.

Математически и вычислительно реализованы единая резольвентная постановка, построение проверочных уравнений с известным решением, прогнозы вероятности точности и времени, семейная проверка и правило выбора трёх приближений. При этом требование $E_j \leq 0{,}01$ не обеспечено для каждого ответа: модель и постоянный $n = 256$ нарушили его на трёх задачах. Положительный перенос на другие классы ОДУ, непрерывную норму ошибки или произвольные начальные условия данным исследованием не установлен.

Поддержка Ремизова и Монте-Карло присутствует в модели, однако в финальном опыте Монте-Карло не выбран ни разу. Его 20 проверенных реализаций были неточны, но $0/20$ не доказывает принципиальной неэффективности метода: исследованы конкретные число траекторий, шаг и задачи. Исторический пример 7 (п. А.7, рисунки Б.25–Б.29) содержит один точный и быстрый МС-ответ из четырёх; он иллюстрирует случайную изменчивость, не добавляется к независимым данным и не подтверждает надёжность следующего запуска.

Дальнейшее исследование обоснованно связано с ранжированием точных приближений, отказом при малой прогнозной допустимости и независимым разделением дисперсии и смещения Монте-Карло. После раскрытия финальных данных модель не настраивалась; новые решения не вычислялись.

Таким образом, реализация обучаемого выбора завершена, а её эмпирическое качество относительно двух постоянных стратегий измерено. Более сильная исходная цель — надёжно выбирать самый быстрый допустимый метод для каждого нового уравнения, включая полезный выбор Монте-Карло, — полностью научно не подтверждена. Исследовательская версия не объявляется гарантированным средством точной доставки.

Предшествующие части исследования. Исследование и оптимизация численной реализации метода Ремизова. Отчёт по проекту №2488, 2026, 10 с.; Сравнение численных методов решения линейных ОДУ и прогнозирование их точности с помощью машинного обучения. Отчёт по тому же проекту, 2026, 6 с.